分布式系统复习大纲

> Author：胡子昂
>
> Date：2018年6月4日 星期一 下午7:06

Chap 2 并行编程平台

2.1

- 微处理器体系结构发展：
  1. 流水线（pipeline）：等同于操作系统流水线。
  2. 超标量执行：有多个流水线，同时执行多条相同流水线阶段的指令。

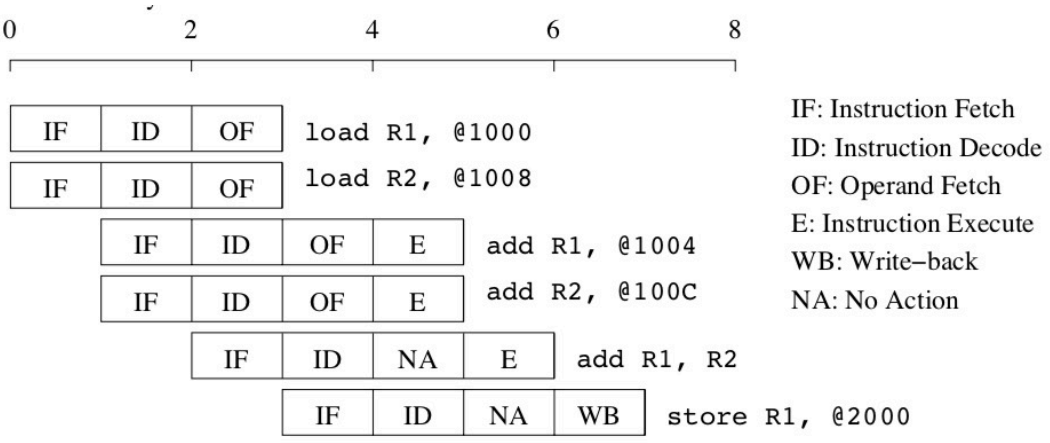

(b) Execution schedule for code fragment (i) above.

2.2

- 内存局限：
  - 延迟：内存收到一条内存字请求，在lus的延迟后，返回数据。则延迟为lus。
  - 带宽：程序每秒钟通过请求内存可获得的最大字节数。
  - 躲避延迟方法：
    1. 预取：预先取更多的数据。
    2. 多线程：一个线程等待时切换到另一个线程。

2.3

- 并行计算平台控制结构：
  - SIMD和MIMD：

    SIMD是单指令多数据流，只有一个控制单元，该控制单元将单个指令交给不同处理器执行，**机器内部需要进行同步**。（并行算法主要研究SIMD）

MIMD是多指令多数据流，每个处理器有一个控制单元，每个控制单元将指令交给对应的处理器执行，**机器内部不需要进行同步**。

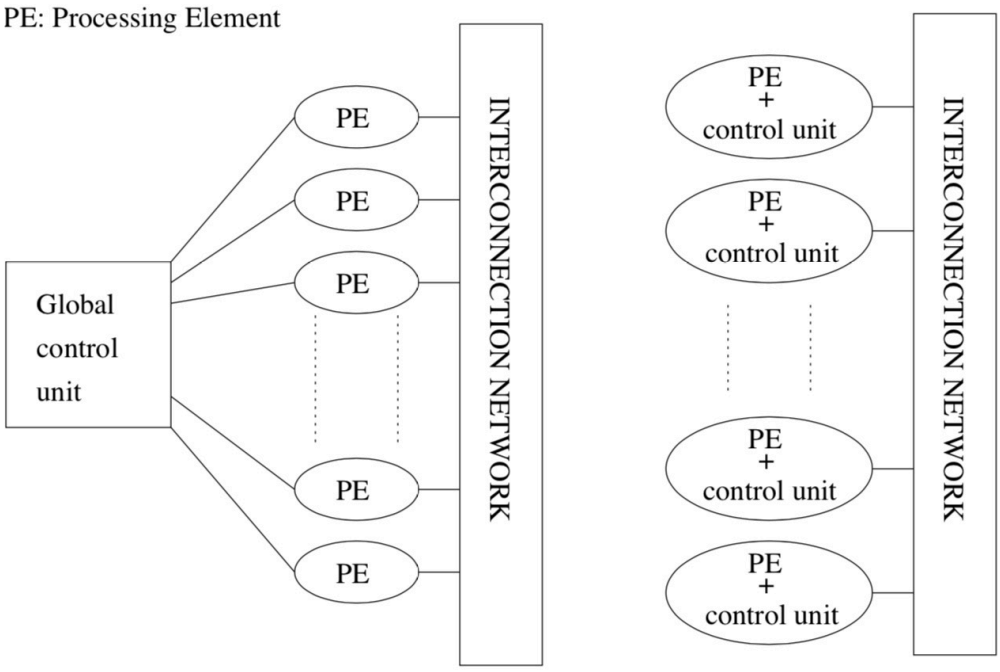

- 并行计算平台通讯模型：
  - SIMD通信模型：共享地址空间平台（PRAM，即共享内存机器）和消息传递平台。

    共享内存一般用于单一计算机内通讯。

    消息传递一般用于计算机之间通过网络通讯。

2.4

- 并行平台物理组织：
  - PRAM的四小类：
    1. EREW：串行读，串行写。
    2. CREW：并行读，串行写。
    3. ERCW：串行读，并行写。
    4. CRCW：并行读，并行写。
  - CRCW（仅限于CW）的四种协议：
    1. 共有：如果处理器写的值相同，则写入。
    2. 任意：当一个处理器写时，其他不能写。（等同于EW）
    3. 优先级：处理器按优先级排序，最高优先级的写，其他不能写。（有优先的EW）
    4. 求和：所有量的总和被写入。类似于O(1)的规约。
- 网络拓扑结构：
  1. 基于总线：所有处理器通过总线进行通讯和访问内存。

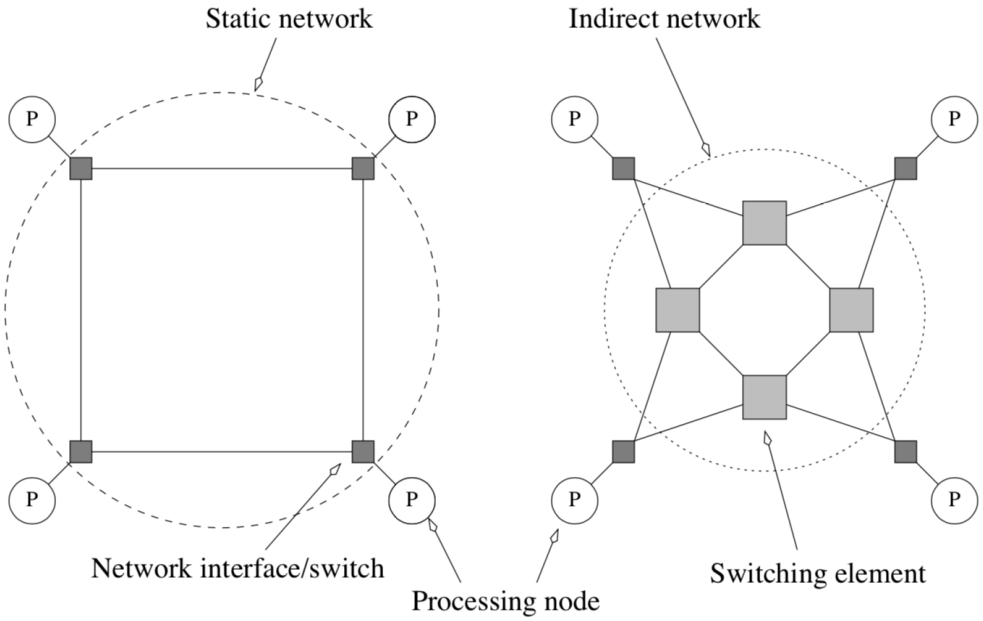

2. 交叉开关网络：n个处理器和m个内存存储地址，用一个n*m矩阵S访问。例如：当S[i][j]打开时，代表第i个处理器正在访问第j个内存储存地址。

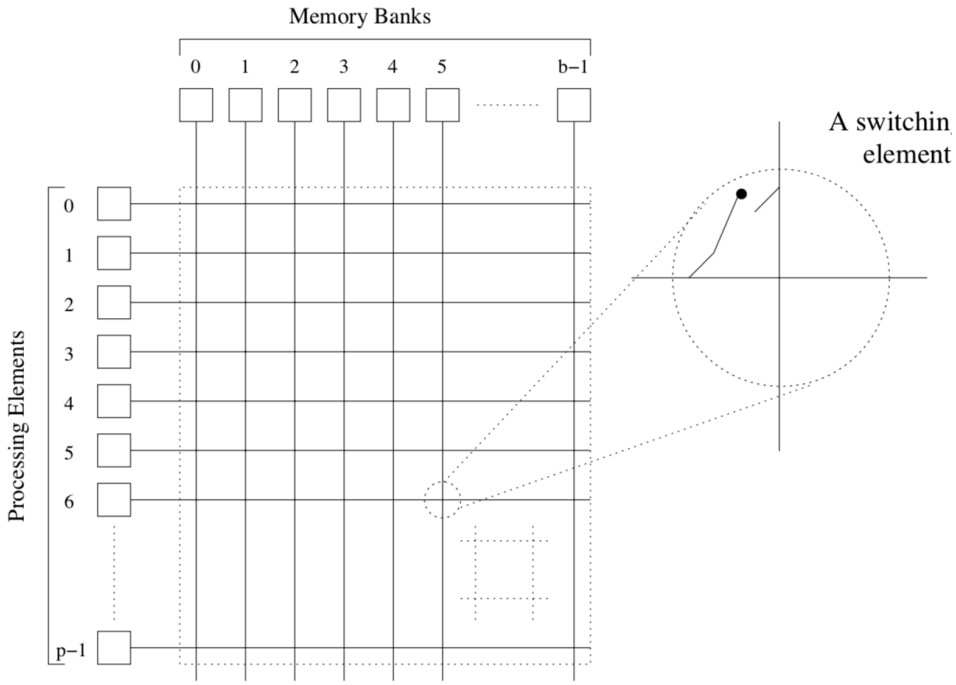

3. 多级网络：多级网络的每个节点开和关代表两种连接，一种是直通式(a)，一种是跨接式(b)。

多级网络的一种连接例子：omega网络。

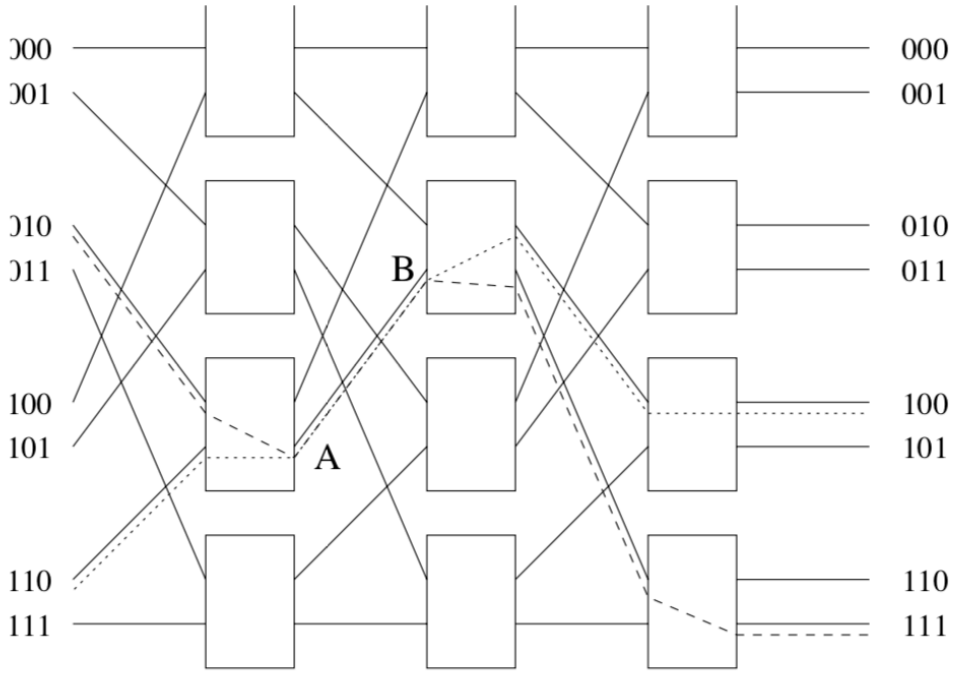

通过切换每个节点的开关，可以将左边8个节点（代表处理器）通过不同方式映射到右边八个节点上（内存）。

Q：如何通过控制开关将左边节点映射到右边节点？例如如何控制节点将S(010)映射到T(111)。

A：先求出s⊕t = 101，1代表交叉，0代表平行。因此s->t途径的三个节点分别是交叉平行交叉(101)。

4. 全连接网络和星型网络：太简单了，略。
5. 线性网络：连一条线，分为有环和无环。
6. 2维格网：2维线性网络，分为有环和无环。
7. k-d格网：有d维，每一维有k个节点。其中，个数为p的线性网络是1-p格网或者p-1格网。
8. 超立方体：看图，和计算机类似的一种多级网络。

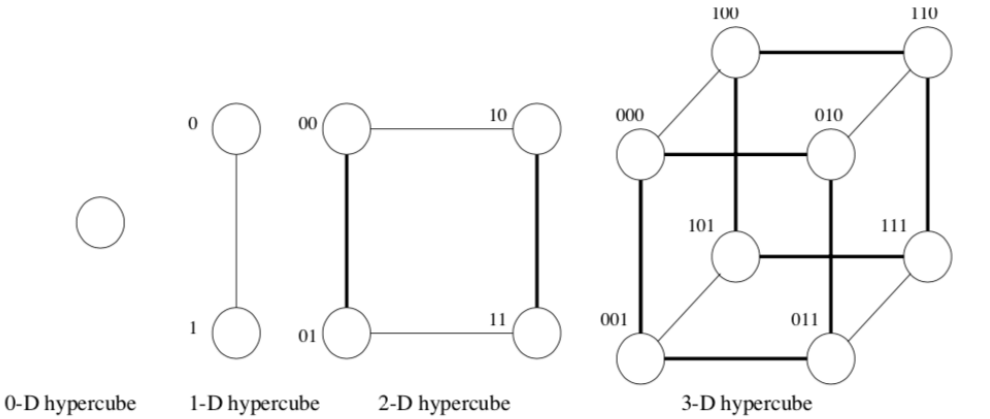

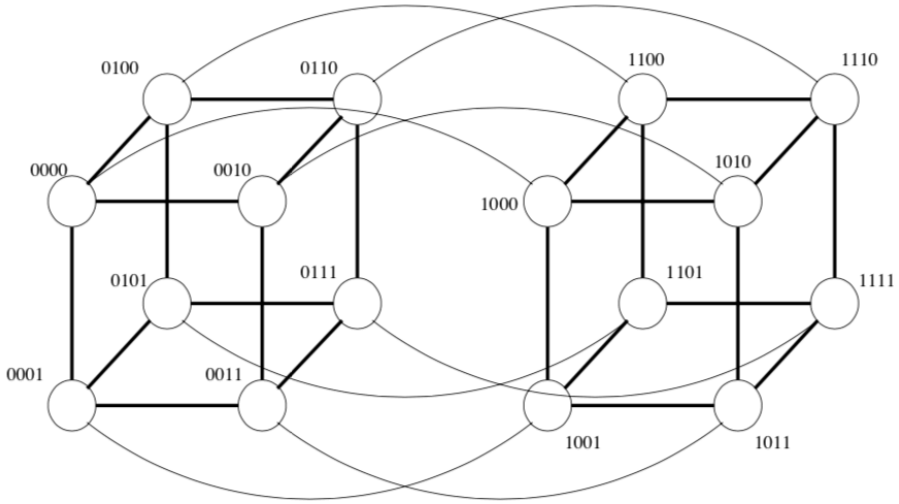

9. 树网络：同数据结构的树，可分为静态树，动态树，胖树。

静态树：非叶节点是处理器。

动态树：非叶节点是开关节点。

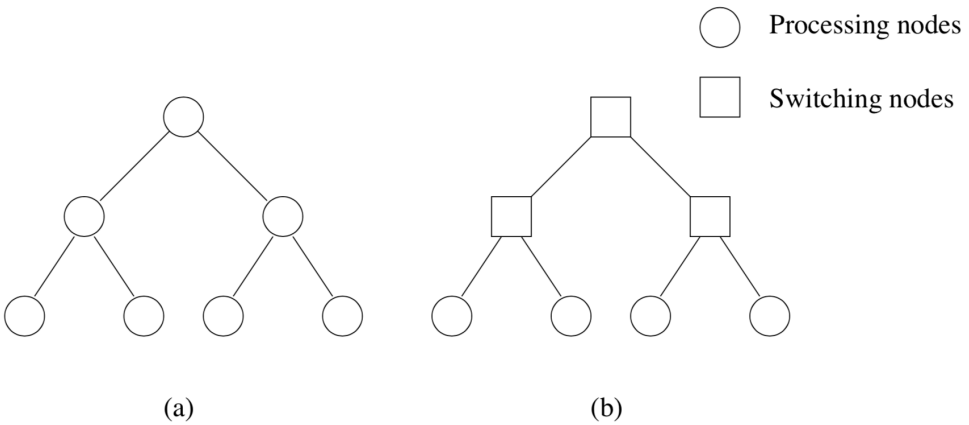

胖树：在动态树的基础上，树层级越高边数越高。

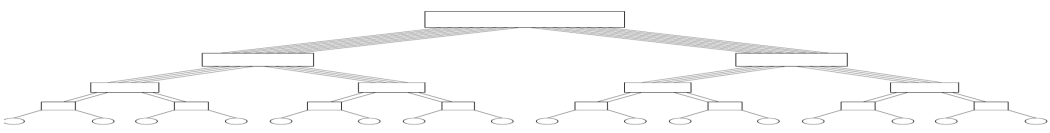

- 静态互联网络评价：
  - 评价参数：
    - 直径：网络任意两个节点之前的最长距离。
    - 弧连通性：等同于找出网络中任意一个节点，该节点的边数量最小，这个值就是连通性值。
    - 对分宽度：如果要将网络等分，最少需要切多少条边。
    - 成本：网络中总共有多少条边。
  - 评价图：

Network	Diameter	Bisection Width	Arc Connectivity	Cost (No. of links)
Completely-connected	1	$p^2/4$	$p-1$	$p(p-1)/2$
Star	2	1	1	$p-1$
Complete binary tree	$2\log((p+1)/2)$	1	1	$p-1$
Linear array	$p-1$	1	1	$p-1$
2-D mesh, no wraparound	$2(\sqrt{p}-1)$	$\sqrt{p}$	2	$2(p-\sqrt{p})$
2-D wraparound mesh	$2\lfloor\sqrt{p}/2\rfloor$	$2\sqrt{p}$	4	$2p$
Hypercube	$\log p$	$p/2$	$\log p$	$(p\log p)/2$
Wraparound *k*-ary *d*-cube	$d\lfloor k/2\rfloor$	$2k^{d-1}$	$2d$	dp

- 动态互联网络评价：
  - 评价参数：除成本都一样。
    - 成本：网络中总共有多少个开关。
  - 评价图：

Network	Diameter	Bisection Width	Arc Connectivity	Cost (No. of links)
Crossbar	1	p	1	p^2
Omega Network	$\log p$	$p/2$	2	$p/2$
Dynamic Tree	$2\log p$	1	2	$p-1$

2.5

- 并行计算机的消息传递成本：
  - 评价参数：
    - 启动时间t_s：发送节点和接受节点处理消息所花的时间，一条消息只有一次。
    - 每站时间t_h：消息在节点之间传输时间。（**非常小，基本没用过**）
    - 每字传输时间t_w：节点接收一个字节所花的时间。
  - 存储转发（store-forward）时间：（l条链路边，数据大小为m）

    $t_{comm} = t_s + mlt_w$

（PS：t_h忽略。）

- 直通路由（cut-through）时间：（l条链路边，数据大小为m）

  $t_{comm} = t_s + lt_h + mt_w$或者$t_{comm} = t_s + mt_w$

  （PS：t_h可以忽略。）

Chap 3 并行算法设计原则（感觉没什么重要的）

3.1

- 分解：把一个计算分解成多个小部分，其中的一些或全部部分可以并行执行。
- 任务：程序员定义的计算单元，分解出的每一部分都可称为一个任务。
- 映射：将其中一个任务映射到其中一个进程上执行。

3.2

- 递归分解：将问题划分成子问题，子问题划分成更小的子问题。（例如：归并排序分解）
- 数据分解：将要处理数据划分成多个部分。其中包括：
  - 划分输入数据。
  - 划分输出数据。
  - 同时划分输入和输出数据。
  - 划分中间结果数据。

Chap 4 基本通讯操作

PS：基本通讯操作一般都是建立在cut-through上。store-forward则只用看直径即可。

PS2：有一种简单的判断T的方法。ts前面的参数是总共进行的步数，tw前面的参数是0节点（首节点）在这个过程中传输的数据量总和

例如：对一对多广播环形陈列，假设有p个处理器，则步数为logp，首节点每步传输的数据固定为m，总共有logp次，则时间为：T = ts logp + tw m logp

4.1 一对多广播和多对一规约

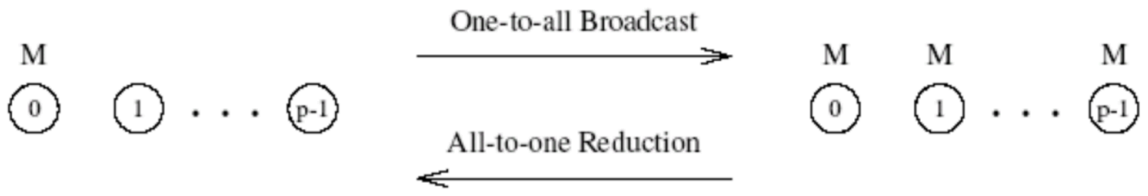

PS：多对一规约就是一对多广播的逆方向

PS2：每一步需要的时间见2.5

- 环形或线性陈列：假设有p个处理器，对收到数据的节点i，分别向i + p/2，i + p/4，i + p/8...传递数据直到所有数据传输完毕。总共需要logp步。

  广播和规约如下图：

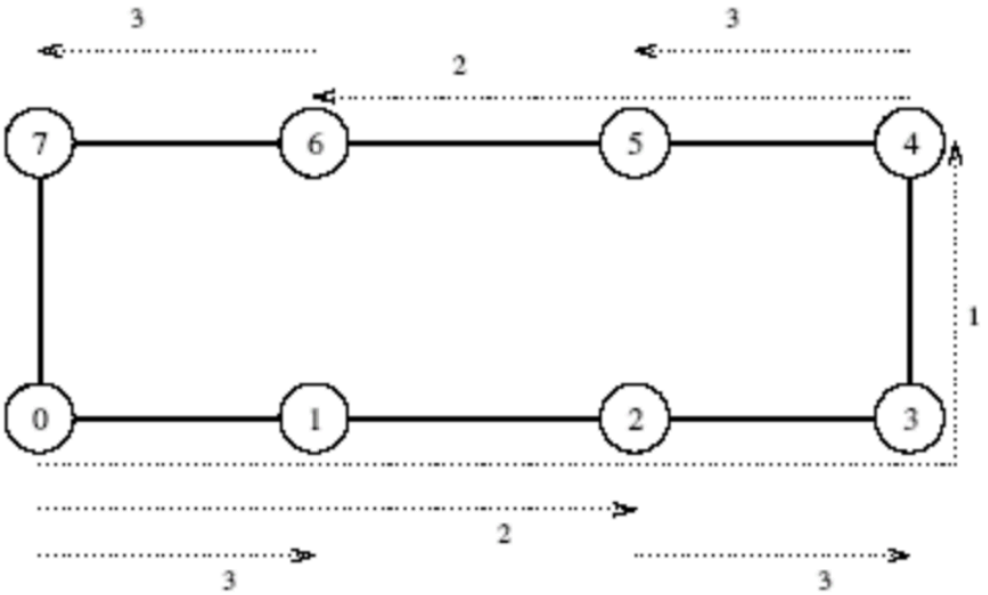

传输到中间节点处
这种方法使传输时没有链路撞车

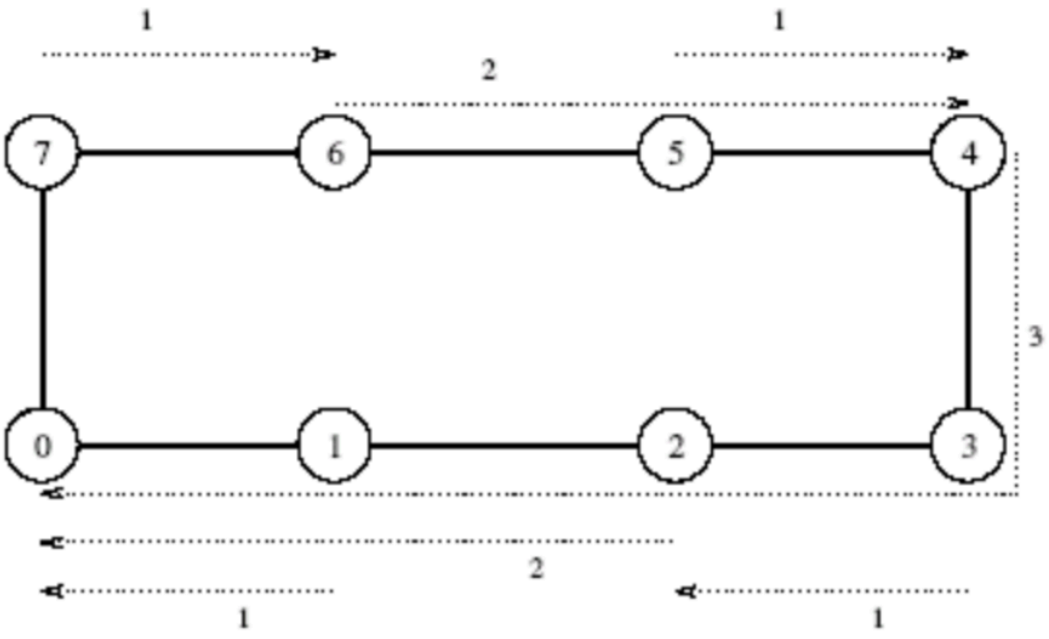

- 矩阵和向量乘法：n*n矩阵S和n*1向量V的乘法，假设有n*n个处理器。

  Step1：n个处理器将向量中的每个元素广播到矩阵中的相应列中，例如将V[i]广播到S的第i列中。

  Step2：每个处理器负责一个节点，进程乘法计算。

Step3：每行的n个处理器进行规约，规约到一个处理器中，得到n*1结果向量。

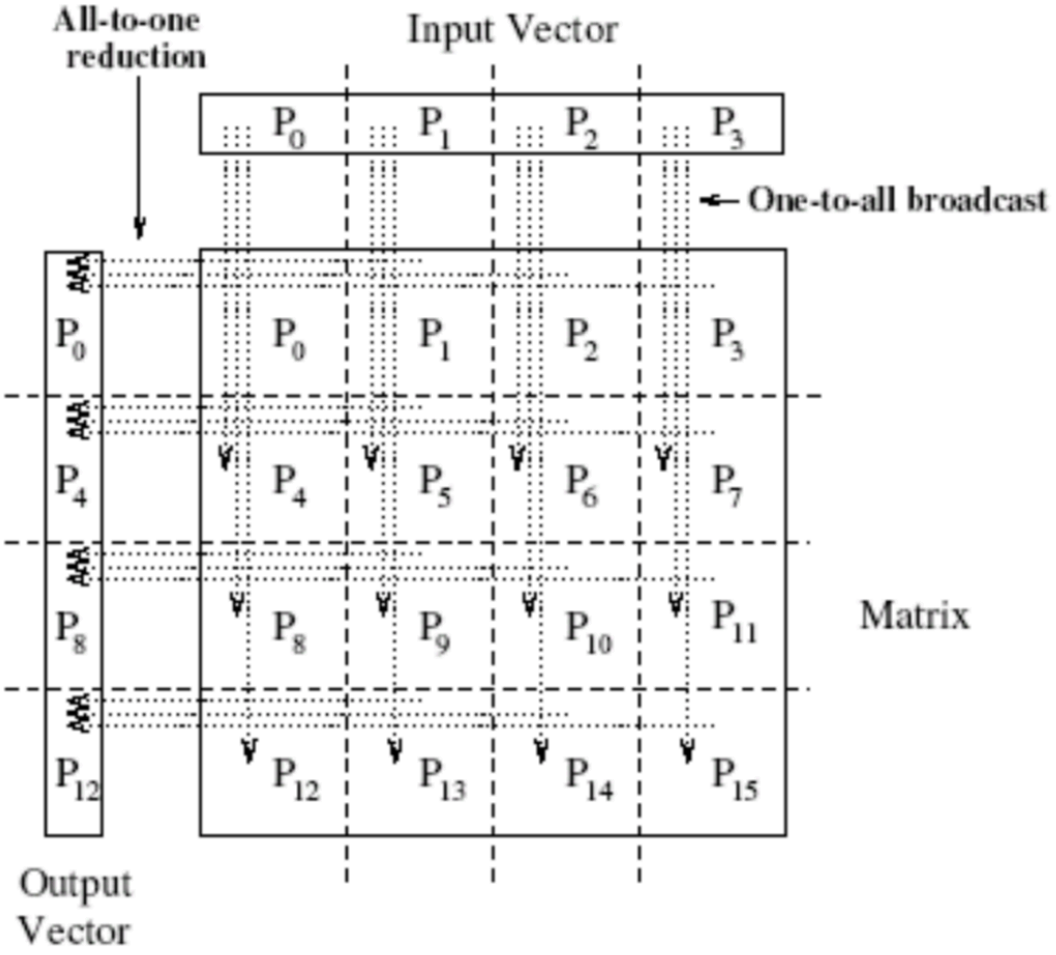

- 格网：横着来一次线性广播，接着竖着来一次线性广播。假设有p个处理器，则总共需要2log√p步，即logp步。
- 超立方体：看作n维格网，由于每增加一维增加相同节点数，因此每传递一维需要一步。假设有p个处理器，则总共需要logp步，即维数。
- 平衡二叉树：做法等同于线性陈列广播。
- 总结：无论哪种情况，广播和规约的时间都为：$T = t_s \log p + t_w m \log p$

4.2 多对多广播和规约

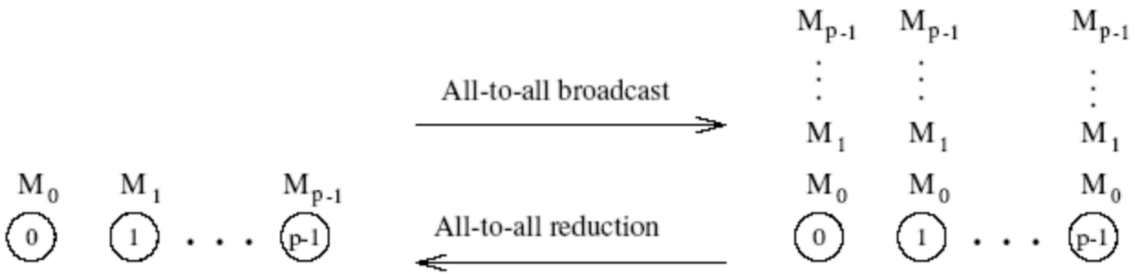

PS：多对多规约与其说是多对多广播的逆方向，不如说是在多对多广播传输数据的基础上，加上数据处理（求和之类的）

- 环形或线性陈列：假设有p个处理器。

  Step1：将自己的数据传输给下一个节点。

  Step2 -> (p-1)：收到上个节点传递过来的数据后，储存该数据，同时把该数据传输给下一个节点。

  通过p-1步后，每个节点都有所有的数据了。

  由于每次只需要传输m大小的数据，因此所花时间为：$T = t_s(p-1) + t_w m(p-1)$

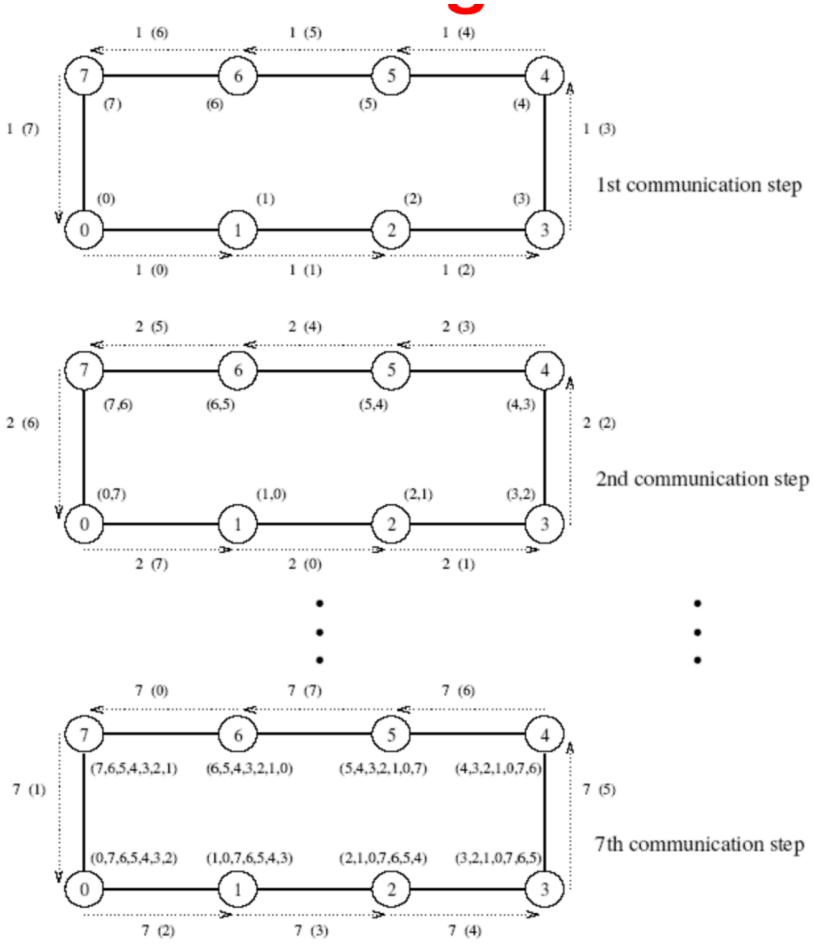

简单的循环移动

- 格网：横着来一次线性广播，接着竖着来一次线性广播。假设有p个处理器，则总共需要2(√p - 1)步。

  由于第一次广播传输的数据量为m，通信时间为$T_1 = (t_s + t_w m)(\sqrt{p} - 1)$，第二次广播传输的数据量为√pm，通信时间为$T_2 = (t_s + t_w \sqrt{p} m)(\sqrt{p} - 1)$。

  两个时间加到一起，总时间为：$T = T_1 + T_2 = 2t_s(\sqrt{p} - 1) + t_w m(p-1)$

- 超立方体：与一对多广播相同，区别是每次节点发送的数据加倍。假设有p个处理器，则总共需要logp步，即维数。

  在第i步中，交换信息的长度为$2^{i-1}m$，花费的时间为$t_s + 2^{i-1} m t_w$。

  将所有时间相加（等比数列求和），总时间为：$T = t_s \log p + t_w m(p-1)$

  三者tw相同（废话），ts根据通讯结构不同。

4.3 前缀和（感觉没什么重要的）

- 每个节点求前缀和的时候，根据自己的节点数选择是否加接收到的数据。

  例如：当节点3(011)在计算前缀和的时候，加第一次(2)和第二次(0 + 1)接收到的数据，最后加上自己即可。

4.4 散发和收集

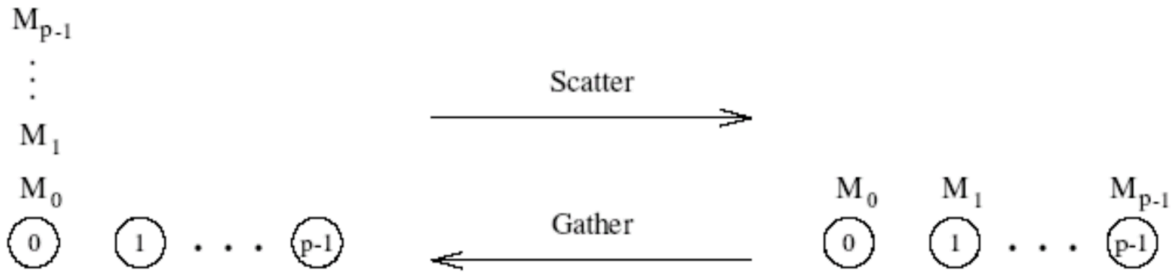

PS：散发发送不同的数据，广播发送相同的数据。

散发方法类似于一对多广播，区别是每次发送的数据不同（减半）

总共时间（三种结构相同）：$T = t_s \log p + t_w m(p-1)$

4.5 多对多私自通讯

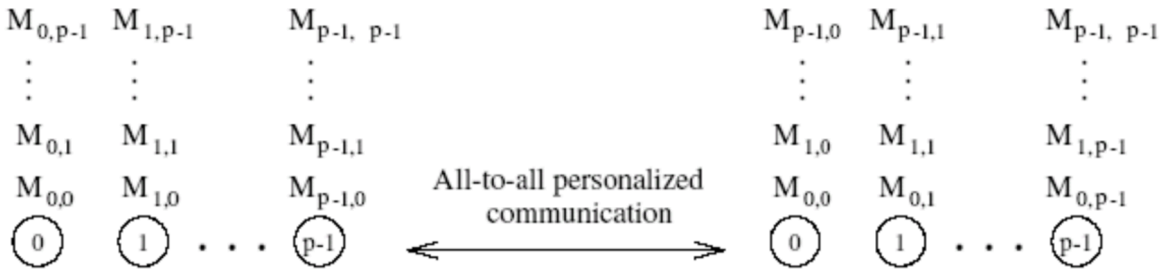

PS：每个节点都同时进行散发

- 环形或线形陈列：假设有p个处理器。

  Step1：将自己想发送给其他人的数据(p-1个)传输给下一个节点。

  Step2 -> (p-1)：收到上个节点传输的数据集合后，取出属于自己的数据，同时把剩下的数据传输给下一个节点。

  通过p-1步后，每个节点都有所有的数据了。

  由于每步需要传输的数据从(p-1)m依次减m直到0，因此所花时间为：
  $T = t_s(p-1) + t_w m\frac{p(p-1)}{2}$
- 网格：横着来一次线性广播，接着竖着来一次线性广播。假设有p个处理器，则总共需要2(√p - 1)步。

  由于